


# LTE 環境における応答遅延特性の 時系列モデリングによる分析

大阪大学大学院情報科学研究科  
○山本 航平, 若宮 直紀

日立製作所 研究開発グループ  
中野 亮, 藤原 亮介

# 研究背景：産業用モニタリングシステム

作業員の巡回による工場内の機器の点検業務



人員コスト  
人的ミスの発生

産業用モニタリングシステムによる自動化

利点

人員コストの削減，人的ミスの低減，  
リアルタイムなデータの利活用など

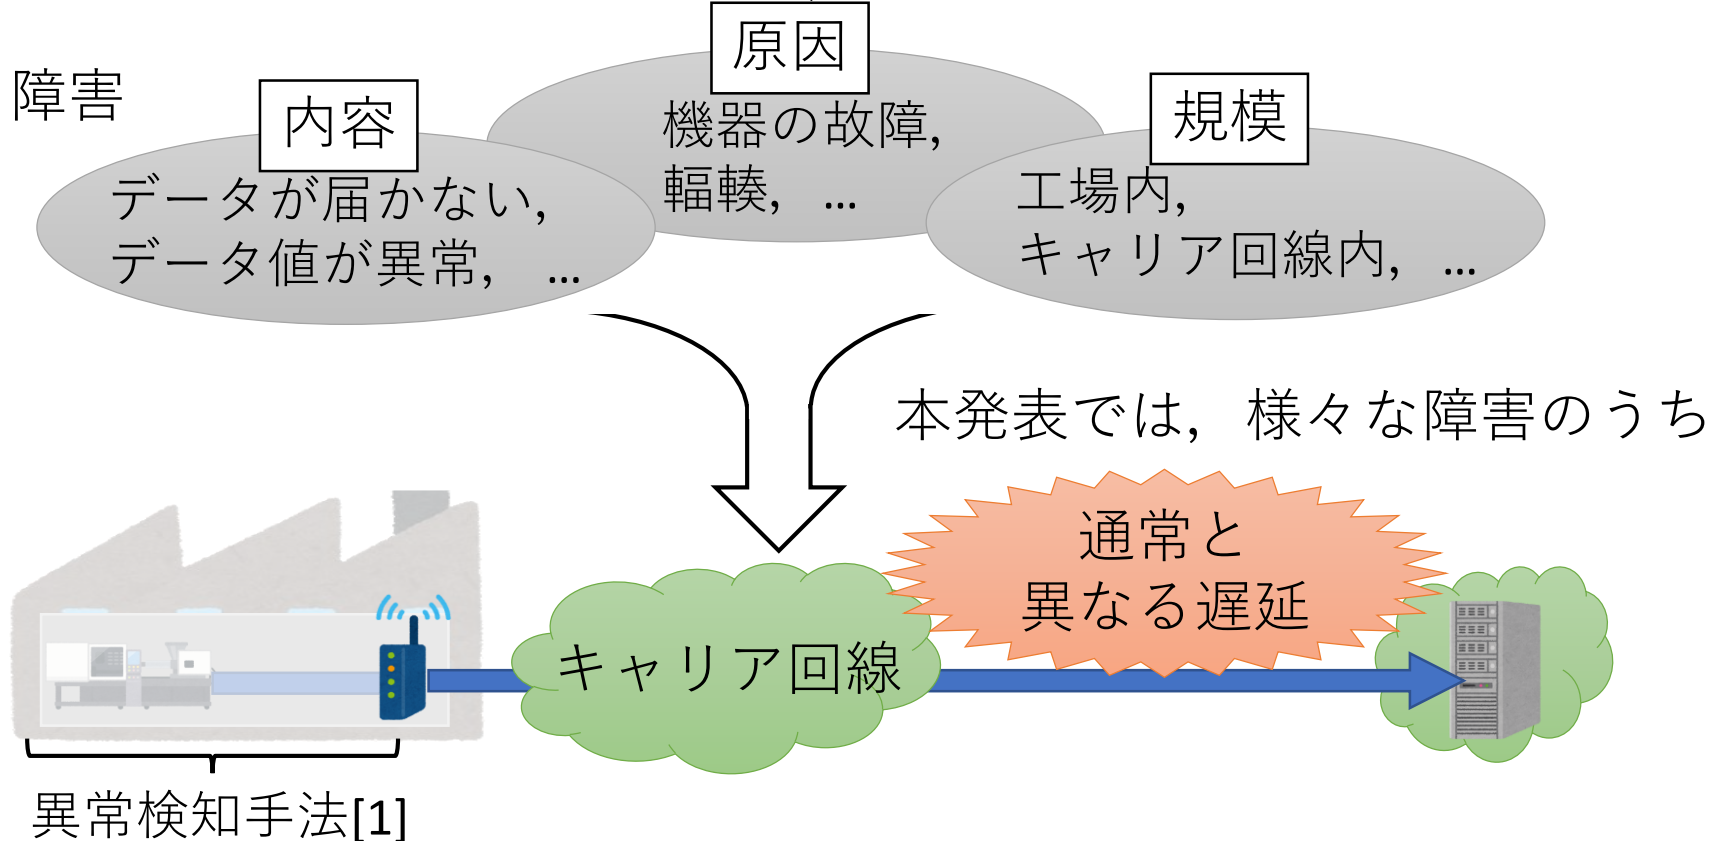


欠点

障害発生時，工場内の機器の稼働状況の把握が困難  
**工場の稼働停止や業務の遅れに繋がり損失が発生**

# 研究目的

障害発生時には迅速な発生検知, 予測が必要



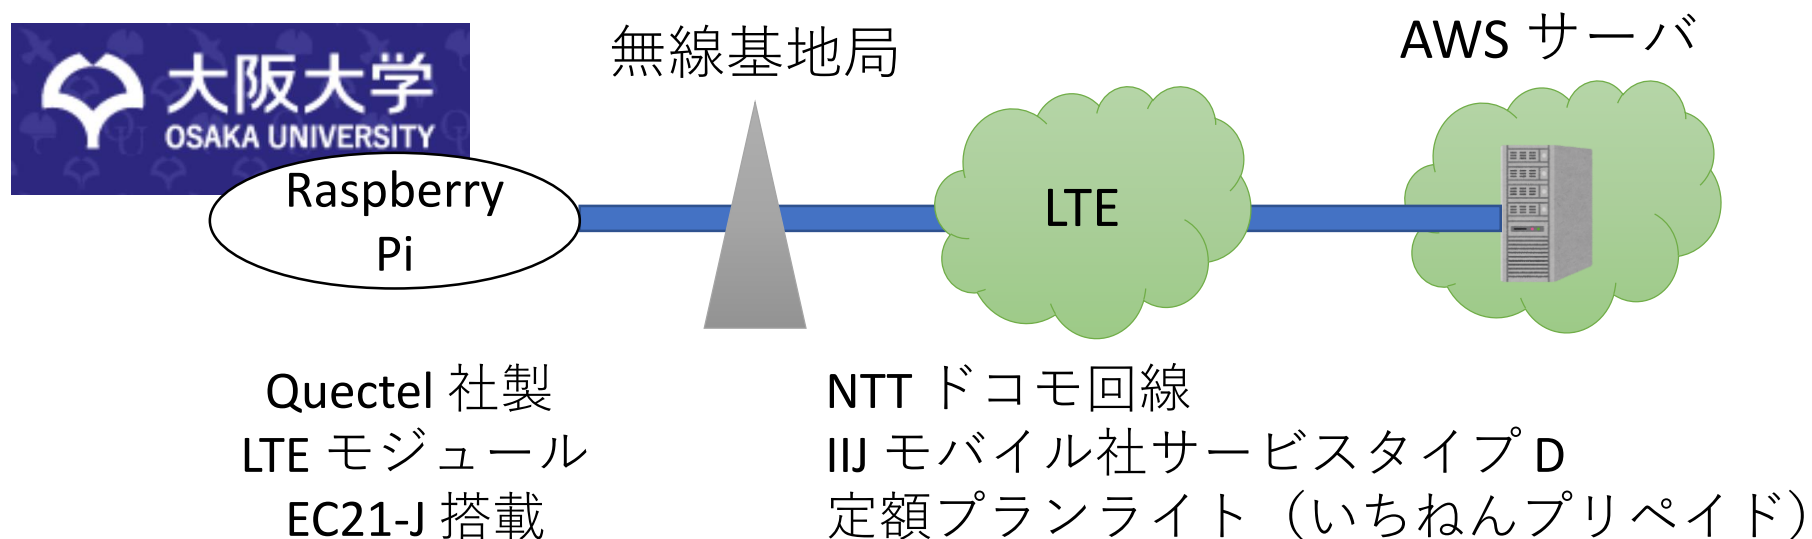
通常の遅延の傾向を捉えるために応答遅延を計測し, 分析

# 以降の発表の流れ

1. 計測方法
2. 分析方法
  - I. 時系列モデリングによる分析
    - ・ ARMA-GARCH モデル
    - ・ モデルの次数設定
    - ・ 回帰結果
  - II. クラスタリングによる分析
    - ・ クラスタリングパラメータの前処理
    - ・ クラスタ数の決定
    - ・ クラスタリング結果

# 計測方法

産業用モニタリングシステムを模擬



Raspberry Pi 上で 15 秒毎に時刻と ping による応答遅延を計測



**時間帯** : 3 時, 7 時, 12 時, 17 時, 20 時のそれぞれ 1 時間

**期間** : 2020 年 2 月 29 日 (土) から 3 月 27 日 (金) まで

# 分析方法


曜日や時間帯が異なる計 122 個の実測値と変動値の区間データ

実測値  $\{x_t\}$



⋮

変動値  $\{\Delta x_t \mid x_t - x_{t-1}\}$



⋮

変化の仕方を分析

時系列モデルによる回帰

曜日や時間帯による傾向を分析

クラスタリング

# ARMA-GARCH (Autoregressive Moving Average – Generalized Autoregressive Conditional Heteroscedasticity) モデル[2]

～時系列モデリングによる分析

$$\underbrace{y_t}_{\text{推定値}} = \underbrace{c}_{\text{実測値}} + \sum_{i=1}^p \underbrace{a_i x_{t-i}}_{\text{ノイズ項を除く推定値}} + \sum_{i=1}^q \underbrace{b_i (x_{t-i} - \hat{y}_{t-i})}_{\text{ノイズ項}} + \underbrace{\varepsilon_t}_{\text{ノイズ項}}$$

$\varepsilon_t$  は平均 0, 分散  $h_t$  の独立同一な正規分布に従う

$$h_t = \omega + \sum_{i=1}^r \alpha_i (x_{t-i} - \hat{y}_{t-i})^2 + \sum_{i=1}^s \beta_i h_{t-i}$$

適切な次数 ( $p, q, r, s$ ) のもとパラメータ  $a_i, b_i, c, \alpha_i, \beta_i, \omega$  を算出

変動値の場合:  $y_t \leftarrow \Delta y_t, x_t \leftarrow \Delta x_t, \hat{y}_t \leftarrow \Delta \hat{y}_t$

実測値と変動値の時系列データはともに定常性を満たす

モデル適用のための前提条件

[2] C.G. Lamoureux and W.D. Lastrapes, "Persistence in variance, structural change, and the GARCH model," Journal of Business & Economic Statistics, vol.8, no.2, pp.225–234, July 1990.

# 共通次数の設定

～時系列モデリングによる分析

各一時間の区間データごとに最適な次数 $(p, q, r, s)$ が存在  
しかし、クラスタリングを行うために共通の次数を設定

AIC（赤池情報量基準）[3] をもとに各区間データごとの  
最適な  $p, q, r, s$  を算出し、それぞれを最大値に設定

$p, q \in \{0, 1, 2\}$ ,  $r = 1$ ,  $s \in \{0, 1\}$  の組み合わせを検討[4]

- 実測値：  $(p, q, r, s) = (2, 2, 1, 1)$
- 変動値：  $(p, q, r, s) = (2, 2, 1, 1)$

[3] H. Bozdogan, “Model selection and Akaike’s Information Criterion (AIC): The general theory and its analytical extensions,” *Psychometrika*, vol.52, no.3, pp.345–370, Sept. 1987.


[4] P.R. Hansen and A. Lunde, “A forecast comparison of volatility models: does anything beat a GARCH (1, 1)?,” *Journal of Applied Econometrics*, vol.20, no.7, pp.873–889, March 2005.



# 実測値に対する回帰結果

～時系列モデリングによる分析


3/2 (月) 3:00 – 4:00



中期的な変化を捉えることが可能

# 変動値に対する回帰結果

～時系列モデリングによる分析



平均	実測値	変動値
平均二乗誤差	230	220
対数尤度	- 959	- 951

僅かに良い回帰結果

# モデルパラメータによる比較

～時系列モデリングによる分析

応答遅延の変化の仕方をモデルパラメータをもとに比較可能

変動値に対するモデルパラメータ


	$a_1$	$a_2$	$b_1$	$b_2$	$c$	$\alpha_1$	$\beta_1$	$\omega$
3月2日(月) 12:00 – 13:00	0.005	-0.038	-1	-0.07	-0.12	0	1	0.29
3月9日(月) 12:00 – 13:00	-0.49	-0.13	-0.49	-0.47	-0.10	0.17	0.85	7.5

変動値に対する重み

$$\Delta y_t = \sum_{i=1}^p a_i \Delta x_{t-i} + \sum_{i=1}^q b_i (\Delta x_{t-i} - \Delta \hat{y}_{t-i}) + c + \varepsilon_t$$

3月9日の方が現在の変動値と過去の変動値との間に強い相関

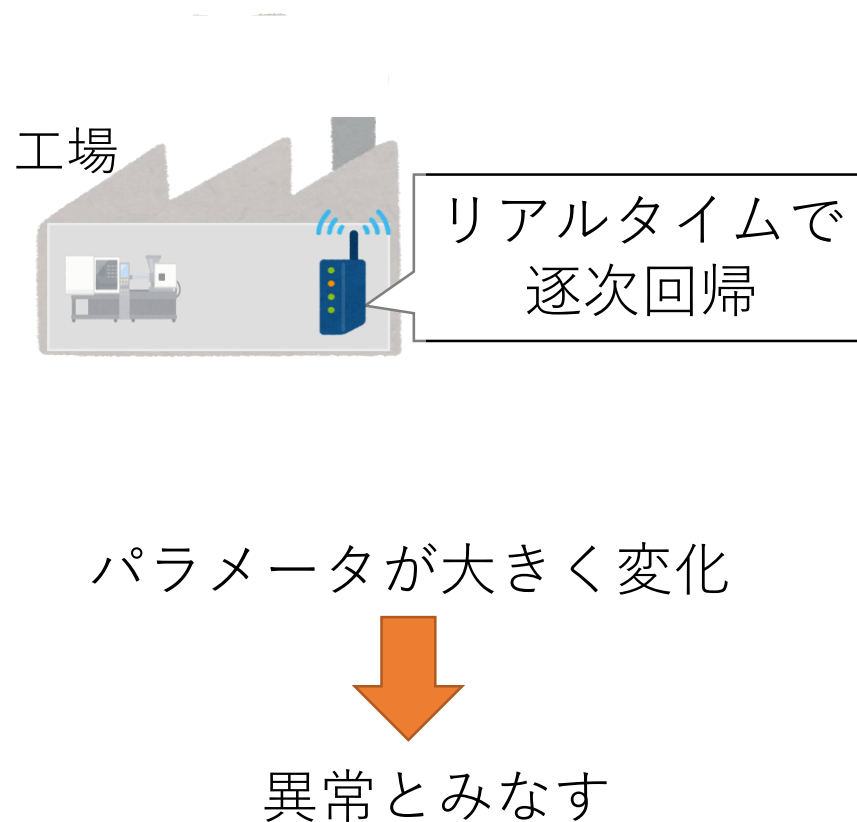

過去の変動値が与える影響の大きさ



# 時系列モデリングによる異常検知手法

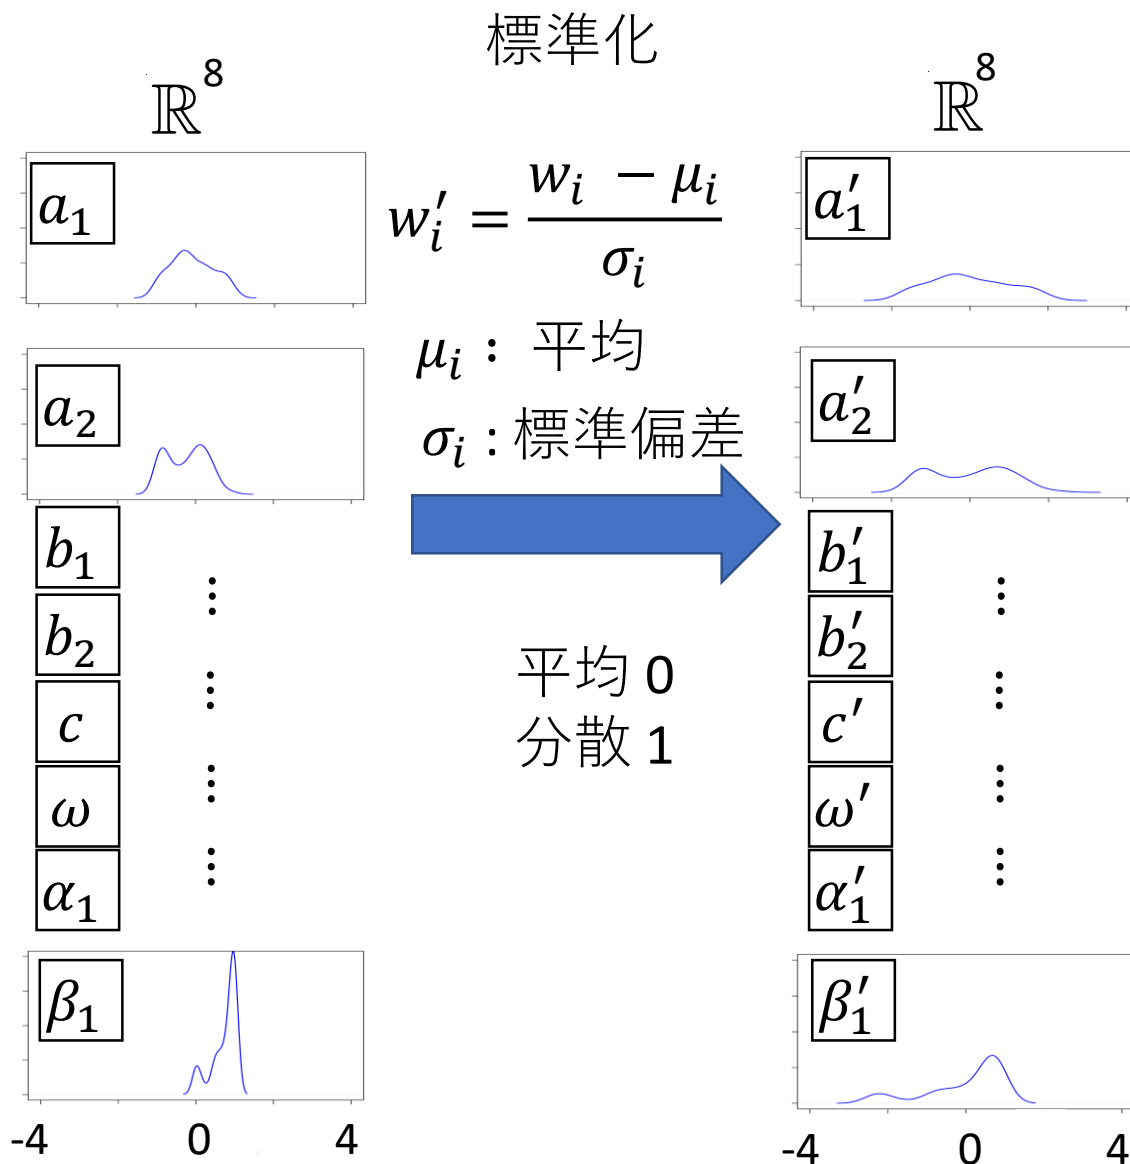
～時系列モデリングによる分析

変動値を用いた ARMA-GARCH モデルによる回帰を使用

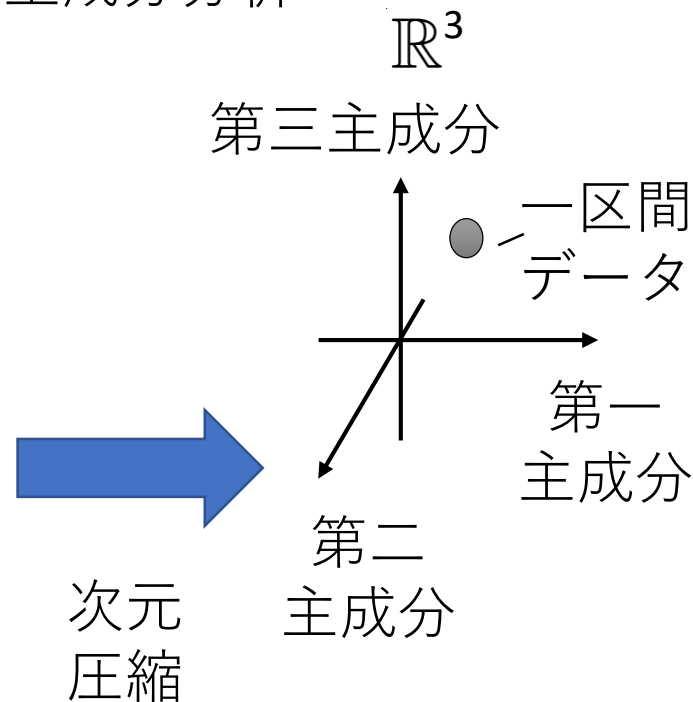


# クラスタリングパラメータの前処理

～クラスタリングによる分析



## 主成分分析



累積寄与率

	第三主成分
実測値	0.86
変動値	0.79

# クラスタ数の設定


～クラスタリングによる分析

Pseudo F with Min [5] を用いて最適なクラスタ数を決定

$$\frac{\sum_{i=1}^k n_i \min \left\{ \text{dist}(\mathbf{m}_i, \mathbf{m}_j)^2 \mid i \neq j \right\}}{1 + \sum_{i=1}^k \sum_{\mathbf{x} \in C_i - \{\mathbf{m}_i\}} \text{dist}(\mathbf{x}, \mathbf{m}_i)^2}$$


$k$  : クラスタ数  
 $C_1, \dots, C_k$  : クラスタ集合  
 $\text{dist}(\mathbf{x}, \mathbf{y})$  : ユークリッド距離関数  
 $\mathbf{m}_i$  : クラスタ  $i$  のメドイド[6]

クラスタ内の凝集性とクラスタ間の離散性の高さを評価



実測値

横軸: クラスタ数




変動値

[5] Ryosuke Kanajiri, "Anomaly detection using incremental clustering and correlation coefficients in industrial wireless sensor networks," Master's thesis, Osaka University, Feb 2020.

[6] K. Mouratidis, D. Papadias, and S. Papadimitriou, "Medoid queries in large spatial databases," in Proceedings of International Symposium on Spatial and Temporal Databases, pp.55–72, Aug. 2005.

# 実測値を用いたクラスタリング 1/3


～クラスタリングによる分析



時間帯での分類

移動通信トラフィックが増加[7]  
ネット利用行為者率が最大[8]

移動通信トラフィックが多い



曜日での分類

一日を通じてトラフィック量が多い


利用者の多い状況での  
応答遅延が似た傾向を  
示した可能性

[7]総務省, 情報通信統計データベース我が国の移動通信トラフィックの現状, <https://www.soumu.go.jp/johotsusintokei/field/tsuushin06.html>

[8]総務省, 令和元年度情報通信白書, <https://www.soumu.go.jp/johotsusintokei/whitepaper/ja/r01/html/nd232500.html>

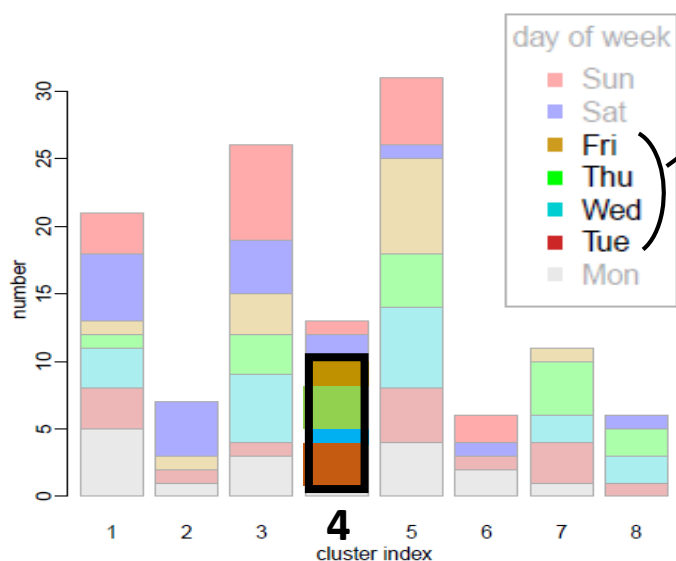
# 実測値を用いたクラスタリング 2/3

～クラスタリングによる分析



通信トラヒックが少ない

時間帯での分類



一日を通じたトラヒック量が少ない


利用者が少ない状況での  
応答遅延に表れやすい  
傾向が存在する可能性

曜日での分類




# 実測値を用いたクラスタリング 3/3

～クラスタリングによる分析



時間帯での分類



曜日での分類

一日を通じてトラヒック量の変化が緩やか

一日を通じてトラヒック量の変化が激しい

通信トラヒックの  
変化が激しい応答遅延が  
似た傾向を示した可能性

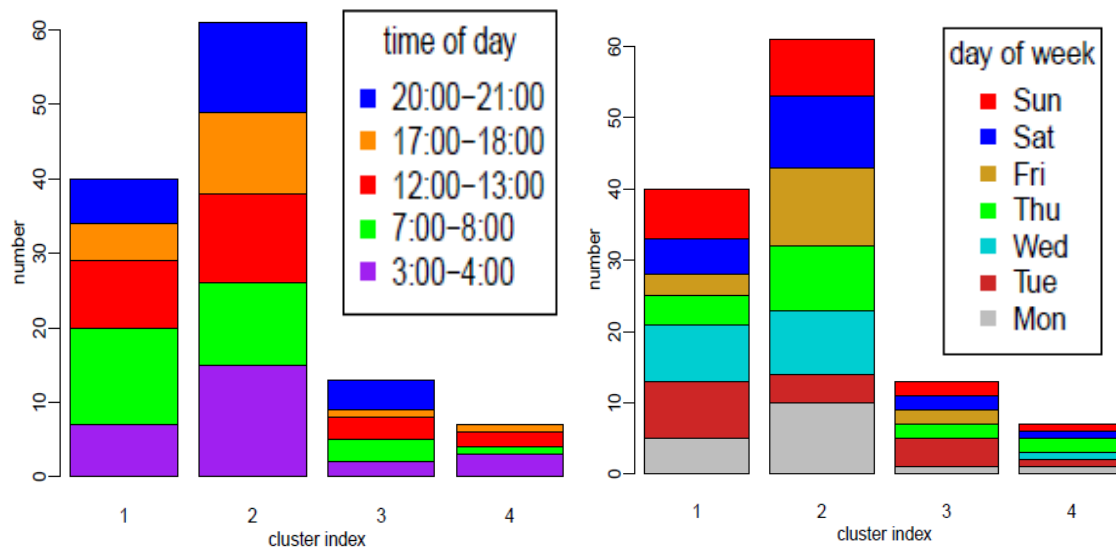
# 変動値を用いたクラスタリング

～クラスタリングによる分析

曜日、時間帯によらず多くのデータがクラスタ 1 と 2 に分類

曜日や時間帯によらず、多くが似た傾向を示しやすい

実測値の大きさによらず、0ms を中心に変化するため



時間帯での分類

曜日での分類

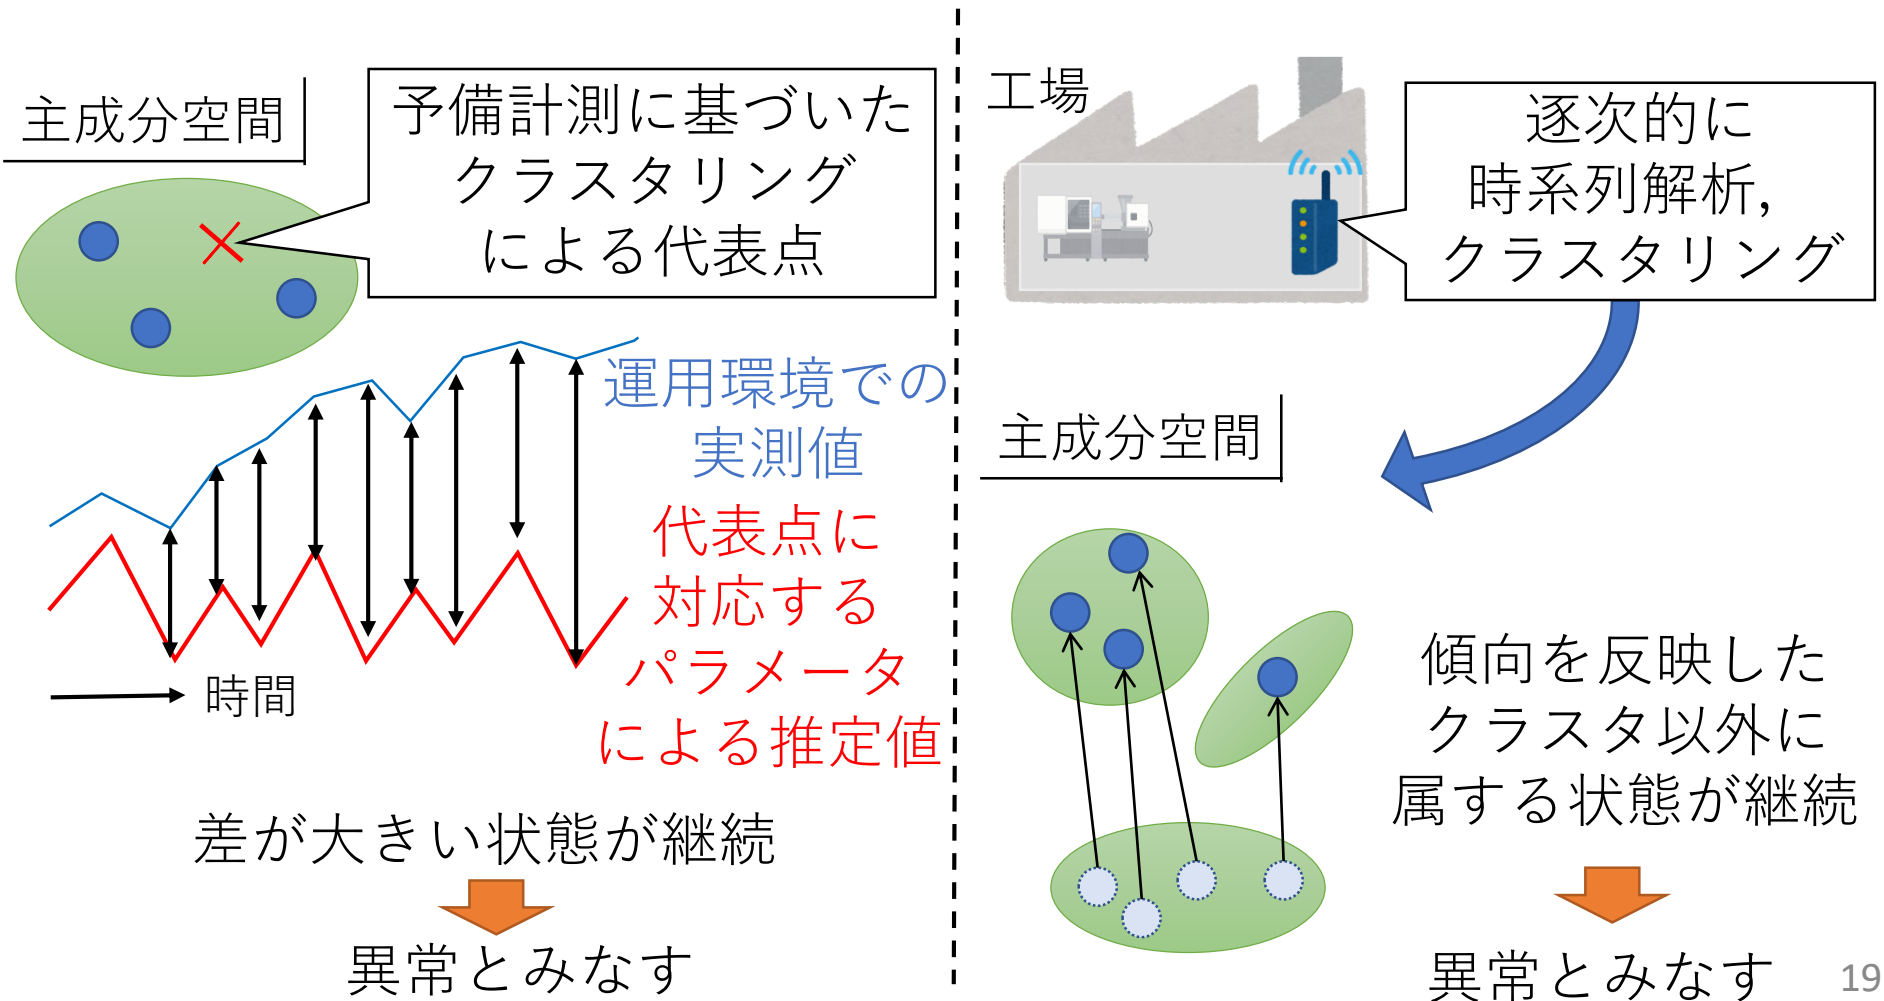
一方で、クラスタ 3 と  
クラスタ 4 は通常時と  
異なる可能性

まとめ：応答遅延の変動の仕方に曜日や時間帯による  
移動通信トラヒックの特徴に応じた傾向が存在

# クラスタリングによる異常検知手法

～クラスタリングによる分析

標準化後の実測値のモデルパラメータの主成分でクラスタリング



# まとめと今後の課題

## ➤時系列モデリング

- 実測値では中期的な応答遅延の変化を捉えることが可能
- 変動値では実測値より平均的に良い回帰精度

## ➤実測値のモデルパラメータの主成分でのクラスタリング

- 応答遅延の変動の仕方に曜日や時間帯による移動通信トラヒックの変化に応じた傾向が存在

## 今後の課題

- 平時と異なるネットワーク利用状況での応答遅延の変動特性を分析
- 分析結果に基づく異常検知手法の設計と有効性の検証
- 他の手法との組み合わせによる精度向上